

Árboles de decisión

Un *árbol de decisión* es un modelo predictivo que utiliza una estructura de tipo árbol para tomar decisiones. Cada nodo interno del árbol representa una prueba o condición sobre un atributo (por ejemplo, “¿La edad es mayor a 30?”), cada rama representa el resultado de esa prueba, y cada hoja representa una predicción o clase final. El árbol se construye dividiendo el conjunto de datos en subconjuntos según el atributo que mejor separa las clases objetivo, utilizando métricas como la ganancia de información o el índice de Gini. Esta estructura permite representar modelos de clasificación o regresión de forma muy intuitiva.

La principal ventaja de los árboles de decisión es su capacidad para trabajar con datos tanto numéricos como categóricos sin requerir una transformación compleja, y su interpretación visual y lógica. Sin embargo, pueden ser propensos al overfitting si el árbol se vuelve muy profundo o complejo, por lo que a menudo se aplican técnicas de poda o se combinan en modelos más robustos como los Random Forest. La elección del atributo para dividir se basa en criterios matemáticos que evalúan qué tan bien una partición reduce la entropía o mejora la pureza del nodo.

Pregunta 1 Una empresa quiere predecir si un cliente comprará un producto en línea. Al construir un árbol de decisión, el analista debe elegir entre las variables “edad”, “tiempo en el sitio web” y “frecuencia de compras anteriores”. ¿Qué criterio se utiliza normalmente para seleccionar la mejor variable en cada nodo del árbol?

- a) La que tenga más valores distintos.
- b) La que maximice la entropía.
- c) La que maximice la pureza de los nodos hijos.
- d) La que tenga la media más baja.
- e) La que produzca nodos con el menor número de muestras.

Pregunta 2 El índice de Gini se calcula como una medida de impureza o heterogeneidad en un conjunto de datos; se utiliza para evaluar qué tan puro es un nodo en un árbol de decisión. Matemáticamente, se define como uno menos la suma de las probabilidades de cada clase al cuadrado, es decir

$$G = 1 - \sum_{i=1}^n p_i^2,$$

donde p_i es la la probabilidad de que un elemento pertenezca a la clase i dentro del nodo. Si todas las instancias pertenecen a una sola clase, el índice de Gini será 0 (pureza máxima), mientras que si las clases están distribuidas uniformemente, el índice se acercará a su valor máximo (por ejemplo, 0.5 en un caso binario con dos clases igualmente distribuidas).

Durante la construcción de un árbol de decisión, un nodo tiene 10 muestras, de las cuales 7 pertenecen a la clase A y 3 a la clase B. ¿Cuál es el índice de Gini de este nodo?

- a) 0.21 b) 0.42 c) 0.49 d) 0.70 e) 0.5

K-means

K-means es un algoritmo de aprendizaje no supervisado utilizado para agrupar datos en clústeres (o grupos) según su similitud. El algoritmo funciona eligiendo un número de clústeres k , asignando aleatoriamente los centroides iniciales y luego distribuyendo los puntos de datos al clúster más cercano. Después, recalcula los centroides como el promedio de los puntos en cada grupo y repite el proceso hasta que las asignaciones se estabilizan. El objetivo es minimizar la suma de los errores cuadrados dentro de cada clúster (WCSS), logrando que los grupos sean lo más compactos y distintos posible.

Un ejemplo de uso se da en la segmentación de clientes en un centro comercial. Imagina que tienes datos de clientes de un centro comercial, con dos variables: ingreso anual y puntuación de gasto. Si graficas estos datos, verás una nube de puntos. Al aplicar K-means con $k = 5$, obtienes cinco grupos representando tipos distintos de clientes: grandes gastadores, ahorradores, compradores frecuentes de bajo ingreso, etc. Esta agrupación te permite tomar decisiones estratégicas, como lanzar promociones personalizadas o diseñar campañas específicas para cada tipo de cliente.

Pregunta 3 Si los ingresos anuales y las puntuaciones de gasto tienen escalas muy diferentes, ¿qué deberías hacer antes de aplicar K-means?

- a) Eliminar las puntuaciones de gasto.
- b) Dividir los ingresos anuales entre las puntuaciones de gasto.
- c) Aplicar una normalización o estandarización de los datos.
- d) Aumentar el número de clústeres.
- e) Usar el algoritmo sin cambios.

Pregunta 4 (K-means++) es una mejora simple pero poderosa del algoritmo K-means tradicional, y su único cambio está en cómo se eligen los centroides iniciales. Esta elección inicial puede tener un gran impacto en la calidad del resultado final, ya que K-means puede quedar atrapado en un mal mínimo local si los centroides iniciales están mal ubicados.

En lugar de elegir los k centroides iniciales completamente al azar, K-means++ selecciona el primero de forma aleatoria, y luego elige los siguientes de manera proporcional a la distancia al centroide más cercano ya elegido, dando preferencia a puntos alejados. Esto garantiza que los centroides iniciales estén bien distribuidos, lo que reduce el riesgo de converger a una mala solución local y mejora tanto la velocidad de convergencia como la calidad de los clústeres resultantes.

¿Por qué K-means++ suele producir mejores resultados que K-means tradicional?

- a) Porque reduce el número de variables necesarias para aplicar el algoritmo.
- b) Porque garantiza que los clústeres serán esféricos.
- c) Porque encuentra más rápido los centroides correctos.
- d) Porque selecciona los centroides iniciales evitando que estén demasiado cerca entre ellos.
- e) Porque siempre encuentra el número óptimo de clústeres automáticamente.

Procesamiento del Lenguaje Natural

Un **tokenizador** es un componente esencial en el *procesamiento de lenguaje natural* (PLN) cuya tarea es segmentar una secuencia de texto (como una frase o un documento) en piezas más pequeñas llamadas “tokens”. Estos tokens suelen ser palabras, números o signos de puntuación, aunque también pueden ser sub-palabras o caracteres dependiendo de la estrategia de tokenización. Este proceso es un primer paso fundamental para que las máquinas puedan analizar y comprender el lenguaje humano.

Pregunta 5 Considerando que existen diferentes estrategias de tokenización (por palabra, por sub-palabra, por carácter), ¿cuál es una consecuencia importante de la elección de una estrategia específica para una tarea de PLN posterior, como el análisis de sentimientos o la traducción automática?

- a) Cambiará el idioma original del texto de entrada.
- b) Afectará directamente el tamaño del vocabulario y la forma en que las palabras desconocidas son manejadas.
- c) Eliminará toda la información sobre la estructura gramatical de las frases.
- d) Hará que el modelo ignore por completo los signos de puntuación.
- e) Se dividirán tan solo las palabras que deben ser divididas, como palabras compuestas.

Pregunta 6 Una incrustación de palabras (**word embedding**) es una técnica que representa las palabras como vectores numéricos densos en un espacio multidimensional. A diferencia de representaciones más simples (como one-hot encoding), estas incrustaciones capturan relaciones semánticas y sintácticas entre palabras, de modo que palabras con significados similares o usadas en contextos parecidos tienden a tener vectores cercanos en ese espacio vectorial. Las incrustaciones de palabras se generan mediante algoritmos de aprendizaje automático, usualmente no supervisados, que se entrenan sobre grandes corpus de texto. Modelos como Word2Vec, GloVe o FastText analizan los patrones de co-ocurrencia de las palabras; es decir, qué palabras tienden a aparecer cerca de otras. Durante el entrenamiento, el algoritmo ajusta los valores de los vectores asociados a cada palabra de forma iterativa, con el objetivo de que los vectores de palabras que aparecen en contextos similares se aproximen entre sí en el espacio vectorial aprendido. En modelos más modernos como los Transformers (ej. BERT, GPT), las incrustaciones se generan también considerando el contexto específico de la oración en la que aparece la palabra (son contextuales). Si modelos como Word2Vec/GloVe generan incrustaciones estáticas, mientras que modelos basados en Transformers generan incrustaciones contextuales. ¿Qué implicación práctica tiene esta diferencia al procesar la frase “La batería del coche está descargada” frente a “El músico tocó la batería”?

- a) Los modelos contextuales generarán representaciones vectoriales diferentes reflejando su significado específico en cada caso, mientras que Word2Vec/GloVe tenderán a usar el mismo vector.
- b) Word2Vec/GloVe asignarán vectores muy diferentes a “batería” en cada frase, capturando perfectamente el significado distinto.
- c) Los modelos basados en transformers son mas rápidos en calcular la representación vectorial de la palabra “batería” para los diferentes casos de uso.
- d) Ninguno de los dos tipos de modelos podrá generar una representación vectorial útil para la palabra “batería” debido a su ambigüedad.
- e) Solo los modelos contextuales podrán tokenizar correctamente la palabra “batería” en ambas frases.

Pregunta 7 Una de las propiedades más fascinantes y demostrativas del poder de las incrustaciones de palabras (word embeddings) es su habilidad para capturar relaciones semánticas y sintácticas complejas de tal manera que estas relaciones se manifiestan como relaciones geométricas (direcciones y distancias) en el espacio vectorial. Esto significa que podemos usar álgebra vectorial simple, como sumas y restas, para navegar por este espacio de significados.

Por ejemplo, si un modelo ha aprendido bien las relaciones entre ciudades y países, la operación

$$\text{vector}(\text{'Madrid'}) - \text{vector}(\text{'España'}) + \text{vector}(\text{'Francia'})$$

debería resultar en un vector cercano a $\text{vector}(\text{'París'})$, capturando la relación “Capital de”. Esto demuestra que el modelo ha aprendido estructuras conceptuales y relacionales del mundo a partir de cómo se usan las palabras juntas en grandes cantidades de texto, permitiendo razonamientos analógicos mediante aritmética vectorial.

Considera un word embedding entrenado con textos sobre ciudades, profesiones y transporte. La operación

$$\text{vector}(\text{'Médico'}) - \text{vector}(\text{'Hospital'})$$

busca aislar la relación abstracta entre un “profesional” y su “lugar de trabajo principal”. Aplicando esta misma lógica relacional, ¿cuál de las siguientes operaciones es más probable que dé como resultado un vector cercano a $\text{vector}(\text{'Piloto'})$?

- a) $\text{vector}(\text{'Enfermera'}) + (\text{vector}(\text{'Médico'}) - \text{vector}(\text{'Hospital'}))$
- b) $\text{vector}(\text{'Aeropuerto'}) + \text{vector}(\text{'Médico'}) - \text{vector}(\text{'Hospital'})$
- c) $\text{vector}(\text{'Piloto'}) - \text{vector}(\text{'Avión'}) + \text{vector}(\text{'Hospital'})$
- d) $\text{vector}(\text{'Médico'}) - \text{vector}(\text{'Hospital'}) + \text{vector}(\text{'Avión'})$
- e) $\text{vector}(\text{'Tecnología'}) + \text{vector}(\text{'Avión'}) - \text{vector}(\text{'Hospital'})$

Redes Convolucionales y Visión Computacional

Una red neuronal convolucional (CNN) es un tipo de inteligencia artificial que se usa sobre todo para analizar imágenes. Su objetivo principal es aprender a identificar qué aparece en una imagen, como un perro, una cara o una letra. Lo hace observando patrones y detalles dentro de la imagen, como bordes, colores o formas. Esto la hace muy útil en tareas como el reconocimiento facial, los autos autónomos o los sistemas de seguridad.

La **convolución** es una operación fundamental en estas redes, que funciona tomando un pequeño cuadro de números llamado kernel (o filtro), que se superpone sobre la imagen y se mueve paso a paso. En cada posición, se multiplican los valores del kernel con los valores de la imagen debajo de él, se suman todos los resultados y ese número se guarda en una nueva matriz, que es la salida de la operación.

Por ejemplo, si tenemos una imagen representada por números en un arreglo 5×5

```
[[ 1, 2, 0, 1, 3 ],
 [ 4, 1, 0, 2, 2 ],
 [ 1, 3, 2, 0, 1 ],
 [ 0, 1, 3, 2, 1 ],
 [ 1, 0, 2, 3, 2 ]]
```

y un kernel 3×3

```
[[ 0, 1, 0 ],
 [ 1, -4, 1 ],
 [ 0, 1, 0 ]]
```

Aplicando convolución en la esquina superior izquierda, tomamos los primeros 3×3 de la imagen

```
[[ 1, 2, 0 ],
 [ 4, 1, 0 ],
 [ 1, 3, 2 ]],
```

luego multiplicamos elemento a elemento con el kernel y sumamos:


```
(1×0) + (2×1) + (0×0) +
(4×1) + (1×-4) + (0×1) +
(1×0) + (3×1) + (2×0) =
0 + 2 + 0 + 4 -4 + 0 + 0 + 3 + 0 = 5
```

El resultado de la convolución tendrá el valor de **5** correspondiente al recuadro 3×3 que consideramos.

Pregunta 8 Usando el mismo arreglo imagen y el mismo kernel ¿Qué valor obtendremos al aplicar la convolución en el recuadro 3×3 en la esquina inferior derecha?

- a) 1 b) 3 c) -3 d) 0 e) -1

Pregunta 9



En PyTorch, cuando aplicamos una convolución usando `torch.nn.Conv2d`, es importante decidir qué hacer con los bordes de la imagen. Para manejar esto, PyTorch ofrece diferentes modos de padding. El valor por defecto es 'valid', donde el filtro (kernel) no se aplica en las zonas donde no puede encajar completamente dentro de la imagen, lo que hace que la salida sea más pequeña que la entrada. Otro muy usado es 'same', que agrega ceros automáticamente alrededor de la imagen para que el tamaño de salida sea igual al de entrada. También se puede usar `padding=1`, `padding=2`, etc., para agregar un borde específico de ceros manualmente.

Si tienes una imagen de tamaño 32×32 píxeles y aplicas una convolución 2D con un filtro de 5×5 , sin agregar padding (es decir, usando el modo 'valid', que es el valor por defecto), ¿cuál será el tamaño del arreglo de salida?

- a) 27×27
- b) 28×28
- c) 30×30
- d) 32×32
- e) 27×32

Pregunta 10 Se aplica el siguiente kernel de convolución a una imagen en escala de grises:

$$K = \begin{bmatrix} -1 & -1 & -1 \\ 0 & 0 & 0 \\ 1 & 1 & 1 \end{bmatrix}$$

¿Qué operación realiza principalmente este filtro sobre la imagen?

- a) Detecta bordes verticales.
- b) Resalta círculos oscuros.
- c) Realiza un desenfoque promedio.
- d) Detecta bordes horizontales.
- e) Aumenta el brillo en regiones oscuras.

Pregunta 11 Considere el siguiente kernel aplicado mediante convolución sobre una imagen en escala de grises:

$$K = \begin{bmatrix} 0 & -1 & 0 \\ -1 & 5 & -1 \\ 0 & -1 & 0 \end{bmatrix}$$

¿Cuál de las siguientes afirmaciones describe mejor el efecto de este filtro?

- a) Realza los bordes y mejora el contraste local.
- b) Suaviza bordes para eliminar ruido.
- c) Realiza detección de bordes diagonales.
- d) Elimina imperfecciones de la imagen.
- e) Aplica una rotación local de los píxeles.

Pregunta 12 Una red neuronal convolucional generalmente trabaja por pasos. Primero utiliza una especie de filtro o “lente” (llamado kernel) que se mueve por la imagen analizando pequeños fragmentos a la vez. Estos filtros buscan detalles específicos, como líneas horizontales, curvas o diferentes tipos de patrones. Luego, esa información se simplifica con una técnica llamada pooling, que ayuda a reducir el tamaño de los datos sin perder lo más importante. Al final, hay una parte que junta todos los resultados anteriores y trata de predecir qué hay en la imagen (por ejemplo, si muestra un gato o un perro), basada en el entrenamiento que utiliza los datos etiquetados para validar las predicciones.

¿Qué hace una red neuronal convolucional durante su entrenamiento?

- a) Copia filtros predefinidos para aplicarlos a cualquier imagen.
- b) Memoriza todas las imágenes para reconocerlas después.
- c) Divide las imágenes en colores para analizarlas por separado.
- d) Aprende a ajustar sus filtros para generar valores que optimicen la función objetivo de la red.
- e) Genera valores probabilísticos que indican cada elemento constitutivo de la imagen.

Pruebas ARC para IAs

Las pruebas ARC (Abstraction and Reasoning Corpus) son un conjunto de desafíos diseñados por François Chollet para evaluar la capacidad de razonamiento abstracto y generalización de una inteligencia artificial. Cada tarea en ARC consiste en transformar una entrada visual (como una pequeña cuadrícula de colores) en una salida, siguiendo una lógica subyacente que debe inferirse a partir de ejemplos. Estas pruebas no requieren conocimientos previos y están diseñadas para medir habilidades similares a las que usamos en tareas de pensamiento humano, como patrones, analogías y reglas generales.

Hasta hace poco, las pruebas ARC representaban un muro casi infranqueable para las inteligencias artificiales. Durante varios años tras su lanzamiento en 2019, los modelos más avanzados fueron incapaces de resolver una fracción significativa de las tareas, quedando muy por detrás del rendimiento humano. Hasta hace poco, los mejores modelos lograban resolver solo un tercio de las tareas del ARC-AGI. Pero en 2024, un concurso con un premio de un millón de dólares impulsó avances significativos. La mejor IA alcanzó un 55.5% de aciertos, un salto considerable desde el 33% previo.

ARC2 es una evolución del conjunto de pruebas original, introducida para ofrecer desafíos aún más complejos y variados

Pregunta 13 La prueba ARC2 ha sido propuesta como una herramienta para evaluar el grado de generalización y razonamiento flexible de los sistemas de inteligencia artificial. Sin embargo, su aparición también ha reavivado debates en torno al verdadero significado de “inteligencia general”. ¿Cuál de las siguientes críticas representa una tensión real en el uso de pruebas como ARC2 para definir el umbral de la inteligencia artificial general?

- a) La prueba ARC2 no es computacionalmente eficiente, lo que impide su uso en modelos comerciales.
- b) La ARC2 ha sido ampliamente aceptada como criterio final para la obtención de inteligencia artificial general por toda la comunidad de IA, eliminando la necesidad de otras métricas.
- c) Algunos críticos argumentan que pruebas como ARC2 refuerzan una visión antropocéntrica de la inteligencia, al exigir que los sistemas artificiales emulen patrones cognitivos humanos.
- d) La ARC2 podría proporcionar a dispositivos futuros la habilidad de tomar decisiones razonadas que podrían afectar el destino de la humanidad.
- e) La ARC2 se basa únicamente en datos visuales, ignorando completamente el razonamiento verbal o simbólico.

Pregunta 14 Las siguientes preguntas son diferentes ejemplos de los retos de ARC2 a los que se enfrentarán las diferentes IAs en 2025, para los cuales también hay premios millonarios. Son pruebas de razonamiento abstracto donde no se le dan muchas explicaciones a la IA.

```
"train": {"input":  
  [[8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8],  
   [8, 8, 8, 8, 8, 8, 1, 0, 8, 8, 8, 8, 8, 8, 8],  
   [8, 8, 8, 8, 8, 1, 1, 8, 8, 8, 8, 8, 8, 8, 8],  
   [8, 8, 8, 8, 8, 1, 8, 8, 8, 8, 8, 8, 8, 8, 8],  
   [8, 8, 8, 8, 8, 1, 8, 8, 8, 8, 8, 8, 8, 8, 8],  
   [8, 8, 8, 8, 8, 3, 3, 3, 8, 8, 8, 8, 8, 8, 8],  
   [8, 8, 8, 8, 8, 8, 3, 8, 8, 8, 8, 8, 8, 8, 8],  
   [8, 8, 8, 8, 8, 8, 2, 2, 2, 8, 8, 8, 8, 8, 8],  
   [8, 8, 8, 8, 8, 8, 8, 8, 2, 8, 8, 8, 8, 8, 8],  
   [8, 8, 8, 8, 8, 8, 8, 8, 2, 8, 8, 8, 8, 8, 8],  
   [8, 8, 8, 8, 8, 8, 4, 4, 4, 4, 8, 8, 8, 8, 8],  
   [8, 8, 8, 8, 8, 8, 4, 8, 8, 8, 8, 8, 8, 8, 8],  
   [8, 8, 8, 8, 8, 8, 6, 6, 6, 8, 8, 8, 8, 8, 8],  
   [8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8],  
   [8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8],  
   [8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8]],  
  "output": [[1], [1], [1], [1], [1], [3], [3], [3], [3], [2],  
             [2], [2], [2], [4], [4], [4], [4], [4], [6], [6], [6]]}
```

Si el test tiene como input

```
"input": [[2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2],  
          [2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2],  
          [2, 1, 1, 1, 1, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2],  
          [2, 0, 2, 2, 1, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2],  
          [2, 2, 2, 2, 3, 3, 2, 2, 2, 2, 2, 2, 2, 2, 2],  
          [2, 2, 2, 2, 2, 3, 2, 2, 2, 2, 2, 2, 2, 2, 2],  
          [2, 2, 2, 2, 2, 8, 2, 2, 2, 2, 2, 2, 2, 2, 2],  
          [2, 2, 2, 2, 8, 8, 2, 2, 2, 2, 2, 2, 2, 2, 2],  
          [2, 2, 2, 2, 8, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2],  
          [2, 2, 2, 2, 8, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2],  
          [2, 2, 2, 2, 8, 4, 4, 4, 2, 2, 3, 3, 2, 2, 2],  
          [2, 2, 2, 2, 2, 2, 4, 2, 2, 1, 2, 2, 2, 2, 2],  
          [2, 2, 2, 2, 2, 2, 2, 4, 4, 1, 1, 2, 2, 2, 2],  
          [2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2],  
          [2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2],  
          [2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2]]
```

¿cuál es el "output"?

- a) [[1], [1], [1], [1], [3], [3], [3], [8], [8], [8], [8], [8],
[8], [4], [4], [4], [4], [4], [4], [4], [4], [1], [1], [1], [3], [3]]
- b) [[1], [1], [1], [1], [1], [1], [3], [3], [8], [8], [8], [8],
[8], [8], [4], [4], [4], [4], [4], [4], [4], [1], [1], [1], [3], [3]]
- c) [[3], [3], [1], [1], [1], [4], [4], [4], [4], [4], [8], [8],
[8], [8], [8], [8], [8], [3], [3], [3], [1], [1], [1], [1], [1]]
- d) [[1], [1], [1], [1], [1], [3], [3], [3], [8], [8], [8], [8],
[8], [8], [4], [4], [4], [4], [4], [4], [4], [1], [1], [1], [3], [3]]
- e) [[3], [3], [1], [1], [1], [1], [4], [4], [4], [4], [4], [8],
[8], [8], [8], [8], [8], [8], [3], [3], [3], [1], [1], [1], [1]]

Pregunta 15 Datos de entrenamiento:

```
"train": {"input":  
  [[0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0],  
   [0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0],  
   [0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0],  
   [0, 0, 0, 0, 0, 0, 0, 0, 3, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0]],  
  "output":  
  [[0, 0, 0, 0, 0, 1, 0, 0, 3, 0, 0, 1, 0, 0, 3, 0, 0, 1, 0],  
   [0, 0, 0, 0, 0, 1, 0, 0, 3, 0, 0, 1, 0, 0, 3, 0, 0, 1, 0],  
   [0, 0, 0, 0, 0, 1, 0, 0, 3, 0, 0, 1, 0, 0, 3, 0, 0, 1, 0],  
   [0, 0, 0, 0, 0, 1, 0, 0, 3, 0, 0, 1, 0, 0, 3, 0, 0, 1, 0]]}
```

Ejemplo de prueba:


```
"test": {"input":  
  [[0, 0, 0, 0, 0, 3, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0],  
   [0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0],  
   [0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0],  
   [0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0],  
   [0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0],  
   [0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 4, 0, 0, 0, 0, 0, 0, 0, 0],  
   [0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0]]}
```

¿Cuál es la segunda fila del arreglo de salida?


- a) [0, 0, 0, 0, 0, 3, 0, 0, 0, 0, 1, 0, 0, 0, 0, 3, 0, 0, 0, 0, 1, 0]
- b) [0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 3, 0, 0, 0, 0, 1, 0, 0, 0, 0, 3, 0]
- c) [0, 0, 0, 0, 0, 0, 3, 0, 0, 0, 0, 4, 0, 0, 0, 0, 3, 0, 0, 0, 4, 0]
- d) [0, 0, 0, 0, 0, 3, 0, 0, 0, 0, 4, 0, 0, 0, 0, 3, 0, 0, 0, 0, 4, 0]
- e) [0, 0, 0, 0, 0, 3, 0, 0, 0, 0, 4, 0, 0, 0, 0, 3, 0, 0, 0, 0, 4, 0]

Pregunta 16 Para que las preguntas sean más fáciles de resolver para humanos, se plantean de forma visual, usando los números como códigos de colores. Aquí está otra pregunta de ARC2.

Datos de entrenamiento:



0	0	0	0	0
6	2	2	2	2
2	0	0	0	0
2	0	0	0	0
2	0	0	0	0



2	2	0	2
0	0	0	2
2	2	2	2
2	0	0	2

Test:

